

中信证券研究部

核心观点



汪洋
量化策略分析师
S1010521090005



王兆宇
首席量化策略分析师
S1010514080008



赵文荣
首席量化与配置分析师
S1010512070002



马普凡
量化策略分析师
S1010520030001



赵乃乐
量化策略分析师
S1010521050001

以收益率为拟合目标的低信噪比问题极大地限制了深度学习在低频量化策略上的应用。本文将合成因子与收益的相关系数作为优化目标，并采用深度网络实现映射关系的学习，构建了深度相关模型（Deep Correlation Model, DCM）。回测结果显示基于相关性的目标函数较直接拟合收益，年化超额收益提升了 7.41%，信息率提升了 0.9。

■ **投资聚焦：重设目标函数，破局低信噪比。**在偏高频的量化投资中，深度学习已经有了较好的应用，但在偏低频的策略上深度学习一方面提升效果不够明显，另一方面还有稳定性弱，解释性差等缺点。导致深度学习不再“强大”的最大困难还是训练数据的低信噪比，尤其是将拟合目标设为收益率的情况下。收益率本身的低信噪比使得产生的错误信号（Error Signal）信噪比也较低。为了解决这一问题，我们将优化目标设为合成因子与收益率的相关系数，以提升错误信号的信噪比。

■ **传统的因子合成方法简介：**1) 等权法，将所有因子标准化后直接等权加总；2) 将所有因子最近一段时期内因子的信息系数（IC）作为权重进行加权；3) 通过优化合成因子的 IC_IR 得到权重进行加权；4) 通过优化合成因子的 IC 得到权重进行加权。线性框架下，方法 3 和 4 有形式相近的解析解。

■ **模型设计：将优化 IC 作为目标函数。**1) 以 IC 为优化目标，一是更关注合成因子的相对大小关系，二是对同一期所有样本计算错误信号，信噪比会更高。2) 进一步改进 IC 为 Weighted IC，可有效避免局部排序与整体相悖的“陷阱”，更好地适应多头选股的任务。3) 神经网络设计：包含两层 32 个单元的全连接层，和两层批标准化层。4) 损失函数：计算 Weighted IC 需要按合成因子的大小进行排序，与权重的顺序对应。对多期的损失计算指数衰减权重加权的的结果作为最终的损失。5) 因子数据及其处理流程。采用了基本面、估值等共计 21 个因子。因子和下期收益均转化为行业市值中性化的排序分位数。

■ **模型测试：有效提升测试集 IC。**1) 5 种基线系统。构造了等权加权、历史 IC 加权、最大化历史 IC、最大化 IC_IR、和 Loss1 神经网络 5 个基线系统用于比较。2) 策略历史表现。在 2012 年 1 月 1 日至 2021 年 10 月 26 日的测试区间上，该策略实现了 16.50% 的年化超额收益，信息率 2.31，超额最大回撤 6.76%。回测结果显示基于相关性的目标函数较直接拟合收益年化超额收益提升了 7.41%，信息比率提升了 0.9。3) 策略分析：DCM 在基准模型 Weighted IC 为负的时候，会带来显著的提升。

■ **结论与投资建议：**设计更加合理的目标函数是一种通过提升错误信号的信噪比，从而提升策略性能的有效手段。基于相关性的目标函数较直接拟合收益年化超额收益提升了 7.41%，信息比率提升了 0.9。

■ **风险因素：**训练的随机性风险、因子效果衰减风险、历史业绩不代表未来表现。

目录

投资聚焦：重设目标函数，破局低信噪比.....	1
传统的因子合成方法简介	1
等权法	1
历史 IC 加权	1
最大化 IC_IR 加权	2
最大化 IC 加权	2
模型设计：以优化 IC 作为目标函数的 DCM 模型.....	2
优化收益预测误差 vs. 优化 IC	2
Weighted IC：更关注头部相关性.....	3
深度神经网络实现非线性映射	4
损失函数的计算流程	4
因子数据及其处理流程.....	5
模型测试：有效提升测试集 IC.....	6
5 种基线系统	6
策略历史表现	6
策略分析：在测试集上实现了更优的 Weighted IC	8
结论与投资建议.....	10
风险因素	10

插图目录

图 1：因子值 VS. 收益率序列一.....	3
图 2：因子值 VS. 收益率序列二.....	3
图 3：神经网络结构图	4
图 4：单期的损失函数计算过程.....	5
图 5：策略的净值走势	6
图 6：各模型相对中证 500 的相对收益	8
图 7：DCM 与等权模型和历史 IC 加权模型的 Weighted IC 的差（训练集）	8
图 8：DCM 与等权模型和历史 IC 加权模型的 Weighted IC 的差（测试集）	9
图 9：等权模型 Weighted IC VS. DCM Weighted IC-等权模型 Weighted IC	9
图 10：历史 IC 加权 Weighted IC VS. DCM Weighted IC-历史 IC 加权 Weighted IC	9

表格目录

表 1：模型涉及的全部指标	5
表 2：策略的历史表现	7
表 3：各模型的历史表现.....	8

■ 投资聚焦：重设目标函数，破局低信噪比

在偏高频的量化投资中，深度学习已经有了较好的应用，因为高频量化投资的 alpha 主要来源于市场统计性的定价错误，这一场景下数据量足够大，且解释因素较少，模型较容易产生效果。然而，在偏低频的量化投资中深度学习一方面提升效果不够明显，另一方面还有稳定性弱、解释性差等缺点，整体性价比大打折扣。导致深度学习不再“强大”的最大困难还是训练数据的低信噪比，尤其是将拟合目标设为收益的情况下。收益本身的低信噪比使得产生的错误信号（Error Signal）信噪比也较低，这给模型训练带来较大困难。

当我们使用深度学习的时候，期望发挥的是其模型容量的优势，因为因子与收益的关系通常不是线性的，深度学习有可能学习到更精准的映射关系。更复杂的模型对训练数据的信噪比也有了更高的要求，在更广阔参数空间下模型依靠低信噪比错误信号的训练难度更高。并且，这样一种困境是传统的抑制过拟合的方法（比如 L2norm）无法解决的，因为此类方法实际是缩小了参数空间，但没有使得训练更加有效。

因此，有效发挥模型容量优势的关键在于提升数据的信噪比，方式之一就是设计更合理的目标函数。在本报告中，我们将合成因子与收益的相关性作为优化目标，该目标函数更加强调整成结果的统计特性。从信息检索¹的角度看，这是一种 List-wise²的做法，统计性的目标函数能够更好的去除噪声的影响，而传统的线性回归对收益/排名的预测是一种 Point-wise 的做法，受噪声的影响更大。

本报告将合成因子与收益的相关性作为优化目标，采用深度网络实现学习，提出深度相关性模型（Deep Correlation Model, DCM）。

■ 传统的因子合成方法简介

等权法

将所有因子标准化后直接等权加总。该方法是一种不做任何先验假设的处理方式。

历史 IC 加权

将所有因子最近一段时期内因子的信息系数（Information Coefficient, IC）作为权重进行加权。这里的 IC 定义为某因子在全部股票的因子暴露值与其下期回报的皮尔逊相关系数。该方法对于因子值与收益相关性更高的因子给与更高的权重。多个时期的 IC 可以取算数平均或者按照指数衰减权重相加，后者可以实现对近期数据更加偏重的效果。

为了防止因子值差距过大或者有异常值影响计算结果，可以使用 RankIC，即某时点某因子在全部股票暴露值排名与其下期回报排名的截面相关系数。

¹ 信息检索解决的是查询结果的排序，与选股具有很高的相似性

² List-wise 是将整个数据看作一个样本，通过直接优化针对所有数据的评价方法或定义损失函数实现。Point-wise 排序是将训练集中的每个实例看作一个样本，优化的是单一样本的误差之和。

最大化 IC_IR 加权

通过优化合成因子的 IC_IR 得到权重进行加权。IC_IR 定义为： $IC_IR = \frac{\text{均值}_t[IC]}{\text{标准差}_t[IC]}$ 。在线性框架下，k 个因子优化问题的目标函数为：

$$\max IC_IR = \frac{\mathbf{w}^T \times IC}{\sqrt{\mathbf{w}^T \Sigma \mathbf{w}}}$$

其中， $\mathbf{w} \in \mathbb{R}^{k \times 1}$ 表示各个因子的权重， $IC \in \mathbb{R}^{k \times 1}$ 表示各个因子多个时期的 IC 均值， $\Sigma \in \mathbb{R}^{k \times k}$ 表示各个因子 IC 的协方差矩阵。该问题有解析解： $\mathbf{w}^* = \Sigma^{-1} \times IC$ 。

最大化 IC 加权

通过优化合成因子的 IC 得到权重进行加权。在线性框架下，k 个因子优化问题的目标函数为：

$$\max IC = \frac{\mathbf{w}^T \times IC}{\sqrt{\mathbf{w}^T V \mathbf{w}}}$$

其中， \mathbf{w} 和 IC 的定义与上一小节一致， V 是当前截面期因子值的协方差矩阵。其最优解为： $\mathbf{w}^* = V^{-1} \times IC$ 。

上述的四种方法中，等权法是一种不做任何先验假设的方法；历史 IC 加权法是一种启发式的方法，为表现好的因子赋予更高的权重，但缺乏数学上的最优性；最大化 IC_IR 加权和最大化 IC 加权是两种线性假设下的学习方法，并且有形式相似的解析解。

模型设计：以优化 IC 作为目标函数的 DCM 模型

优化收益预测误差 vs. 优化 IC

传统的多因子策略做法是直接对收益率或者排名进行预测，目标函数一般为均方误差。然而，这种目标函数产生的错误信号的信噪比较低，不利于模型的学习。对于如何更好地应用机器学习方法这一问题，我们在《量化策略专题研究—机器学习在量化投资中的应用探讨》（2020-2-4）中提到过“跳出收益率预测的思维定式，寻找信噪比更高的对象进行学习”。尤其是想要使用更复杂的模型时，学习目标的信噪比是性能好坏的关键。

在传统多因子策略中，通常按照如下的优化目标进行训练。其中 $\mathbf{x}_{t,i}$ 表示第 t 期第 i 个股票的因子向量， $y_{t,i}$ 表示该股票下一期的收益。当模型为线性时， $f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i$ 。

$$\text{Loss1} = \sum_t \sum_i (y_{t+1,i} - f(\mathbf{x}_{t,i}))^2$$

而在因子合成中，优化 IC 的目标函数为：

$$\text{Loss2} = - \sum_t \text{Corr}(y_{t+1,i}, f(\mathbf{x}_{t,i}))$$

其中， $\mathbf{x}_{t,i}$ 和 $y_{t+1,i}$ 含义同上，Corr 表示皮尔逊相关系数。

这两种目标函数有两个明显的差异：

1. Loss1 中会使每一个 $x_{t,i}$ 经过 f 映射后靠近 $y_{t+1,i}$ ，但可能带来的是整体均值上的靠近， $f(x_i)$ 对于 y_i 的顺序并没有做显性拟合；Loss2 中更关注同一期所有 $f(x)$ 和 y 的相关性，也即两者的顺序相似性。对于策略尤其是多头选股策略， $f(x_i)$ 的相对大小是更加重要的。


2. Loss1 将不同期的样本和截面上的样本均看作独立样本，对每一个样本点分别计算损失然后加总；Loss2 是将每一期的样本看作一个整体，对整体的结果计算相关性作为损失，较单一样本直接加总的损失具有更高的信噪比。另外，对不同期分别计算相关性也有助于去除一些时序上的噪声。

对比之下，因子合成的目标函数具有更高的信噪比。

Weighted IC：更关注头部相关性


由于 IC 描述的是整体样本的统计性，所以局部上可能出现与整体结果截然相反的分佈，比如整体的 IC 是正值，但在因子值较高的区域 IC 是负值，这一“陷阱”有可能严重影响多头选股的效果。如下图所示，因子值和收益率序列均已转化为排序分位数，两种情况下相关性均为 0.2364。但是如果根据因子值选取前 3 只股票构建组合的话，第二种情况的结果将会非常糟糕。

图 1：因子值 VS. 收益率序列一



资料来源：中信证券研究部

图 2：因子值 VS. 收益率序列二



资料来源：中信证券研究部

为了更好地适应多头选股的任务，可以采用加权的相关系数，即计算 y 和 $f(x)$ 的 Weighted IC。采用的权重为指数衰减权重，表达式如下，因子值最高的权重为 1，最低的为 0.5：

$$w_i = 0.5^{\frac{i-1}{n-1}}, i = 1, \dots, n$$

其中， i 为因子值的从高到低的排序， n 为股票的数目，最后再进行归一化。Weighted IC 计算过程如下：

$$\text{Mean}[x, w] = \sum_i w_i x_i, \text{Mean}[y, w] = \sum_i w_i y_i$$

$$\begin{aligned}\text{Var}[x, w] &= \sum_i w_i x_i^2 - \text{Mean}[x, w]^2, \text{Var}[y, w] = \sum_i w_i y_i^2 - \text{Mean}[y, w]^2 \\ \text{Cov}[x, y, w] &= \sum_i w_i x_i y_i - \text{Mean}[x, w] \times \text{Mean}[y, w], \\ \text{Corr}[x, y, w] &= \frac{\text{Cov}[x, y, w]}{\sqrt{\text{Var}[x, w]} \times \sqrt{\text{Var}[y, w]}}\end{aligned}$$


将指数衰减权重应用到上述案例中，可得到情况一中的加权 IC 为 0.3654，而情况二中的为 0.0868。

截面上采用 Weighted IC 可以使模型更加关注头部的相关性，在时序上也可以使用指数衰减的权重以提升近期数据的重要性。

深度神经网络实现非线性映射

上述的映射 f 采用深度神经网络来实现，结构如下图所示。其中，输入层为 21 个因子值，第二层为 32 单元的全连接层，然后为批标准化（Batchnorm）层³；再次重复 32 单元全连接层和批标准化层，最后到输出层。

图 3：神经网络结构图



资料来源：中信证券研究部

损失函数的计算流程

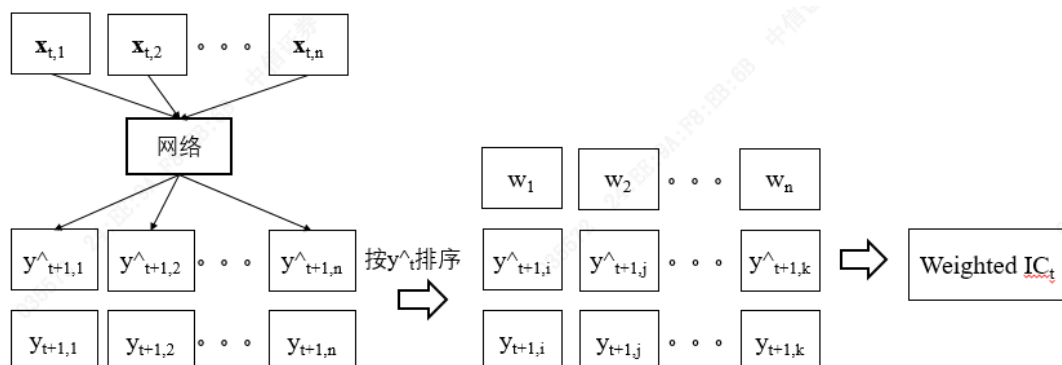
损失的计算过程如下图所示。第 t 期第 i 个股票的因子向量 $\mathbf{x}_{t,i}$ ，经过网络映射后输出的预测“分数”为 $\hat{y}_{t+1,i}$ ，真实的分数为 $y_{t+1,i}$ ，由于计算 Weighted IC 需要将权重 w_i 的顺序与 $\hat{y}_{t+1,i}$ 的顺序对应，故按 $\hat{y}_{t+1,i}$ 大小进行排序后可进行 Weighted IC 的计算。这里采用的权重 w_i 为前文所述的指数衰减权重。最后，对多期的损失计算指数衰减权重加权的作为最终的损失。

至此，我们采用 Weighted IC 作为优化目标，采用 DNN（Deep Neural Network）实现映射的学习，构建了一个新的多因子策略模型，命名为深度相关性模型（Deep

³ 批标准化可以有效防止“梯度弥散”，提升训练速度。

Correlation Model，以下简称 DCM)。

图 4：单期的损失函数计算过程



资料来源：中信证券研究部

因子数据及其处理流程

我们采用的因子如下表所示，共计 21 个，分属 8 大类。对每一指标计算其分位数，在计算 IC 时则自动为 RankIC 以提升稳定性。具体步骤如下：

1. 对样本空间的股票按照中信一级行业分为 30 组。
2. 在每一个行业组内按市值排序分为 3 组，则截面上共计有 90 个小组。
3. 在每一个小组中对每一个因子排序，并转化为排序分位数，即：小组排序/小组股票数。
4. 对于下一期的收益，我们也采用上述同样的做法。

经过上述的处理，因子和收益都进行了行业市值中性化。

表 1：模型涉及的全部指标

指标维度	指标描述	方向
偿债能力	有息负债/总资产	-
	短期负债/货币资金	-
盈利能力	净资产收益率(TTM)	+
	销售毛利率(TTM)	+
	单季度净资产收益率	+
	单季度销售毛利率	+
	单季度扣除非经常损益后的净利润 / 净利润	+
	单季度经营活动产生的现金流量净额 / 营业收入	+
盈利波动性	净资产收益率波动性	-
	毛利率波动性	-
成长能力	单季度营业收入同比增长率	+
	单季度净利润同比增长率	+
经营能力	存货周转率	+

	应收账款周转率	+
	总资产周转率	+
分析师	一致预期营收同比	+
	一致预期净利润同比	+
	一致预期 2 年复合增长率	+
	4 周一致预期净利润变化率	+
投资者认可度	北向持有占比	+
估值分位数	EP 5 年分位数	+

资料来源：中信证券研究部

■ 模型测试：有效提升测试集 IC

5 种基线系统

我们构建如下 5 种模型作为对比的基线系统：

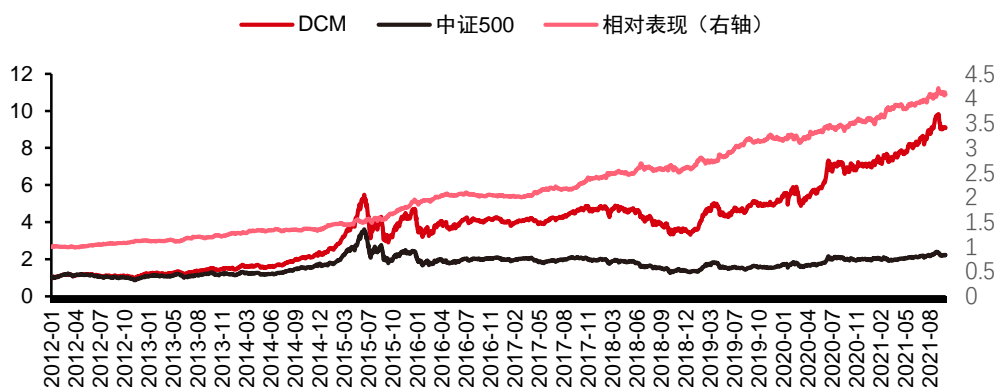
1. 等权加权。直接将所有因子的值等权加总。
2. 历史 IC 加权。计算每个因子过去 3 年的平均 IC，并以 IC 值作为权重加总所有因子。
3. 最大化 IC。按照最优解形式计算权重并以此加总所有因子。
4. 最大化 IC_IR。按照最优解形式计算权重并以此加总所有因子。
5. Loss1 神经网络，结构和图 3 中的一致，但目标函数采用前文描述的 Loss1。

对于以上五种基线系统，以全市场非 ST 股票为样本空间，均选择分数最高的 100 只股票，行业内按自由流通市值加权，行业间按中证 500 行业权重加权；涉及最优化的方法 3、4、5 均采用过去 3 年的数据；调仓频率为月度，交易手续费设为单边 3%。DCM 模型也采用相同的设置，与基线系统唯一的差异就是各自输出的“分数”不同。测试区间为 2012 年 1 月 1 日至 2021 年 10 月 26 日。

策略历史表现

在测试区间上，DCM 策略整体实现 16.50% 的年化超额收益，信息率 2.31，超额最大回撤 6.76%。分年度来看，除 2016 年和 2018 年偏弱外，其它年份均能实现 10% 以上的超额收益。

图 5：策略的净值走势



资料来源：Wind，中信证券研究部

表 2：策略的历史表现


	年化收益 (%)	年化超额收益 (%)	年化波动率 (%)	年化超额波动率 (%)	夏普比率	信息率	最大回撤 (%)	超额收益最大回撤 (%)	最大回撤天数
全部	24.89	16.50	25.31	7.16	0.98	2.31	46.92	6.76	65
2021	35.17	20.77	16.19	8.41	2.17	2.47	8.47	3.52	10
2020	34.88	14.29	24.46	8.22	1.43	1.74	17.40	5.05	13
2019	53.24	27.35	20.58	7.65	2.59	3.57	15.12	4.43	39
2018	-27.08	5.91	23.74	8.21	-1.14	0.72	31.90	6.76	155
2017	17.32	17.52	13.34	5.82	1.30	3.01	7.83	3.44	35
2016	-13.50	4.01	31.16	5.87	-0.43	0.68	30.85	4.03	20
2015	98.51	56.23	44.21	9.44	2.23	5.95	46.92	5.54	65
2014	49.04	10.96	19.34	6.02	2.54	1.82	10.36	3.63	63
2013	32.61	15.57	21.38	5.71	1.53	2.73	14.78	3.80	16
2012	15.42	12.83	22.56	4.72	0.68	2.72	21.01	2.79	177

资料来源：Wind，中信证券研究部

与基线系统进行对比，可以观察到一些局部变化带来的效果提升。首先对比 DCM 和 Loss1 神经网络模型，可以看到更换目标函数后，年化超额收益提升了 7.41%，信息率提升了 0.9。

对比 DCM 和最大化 IC 模型，可以看到线性向非线性转换后的效果，年化超额提升了 2.98%，信息率提升了 0.22，并且 2015 年至今的效果要明显更好。

图 6：各模型相对中证 500 的相对收益



资料来源：Wind，中信证券研究部

表 3：各模型的历史表现

	年化收益(%)	年化超额收益(%)	年化波动率(%)	年化超额波动率(%)	夏普比率	信息率	最大回撤(%)	超额收益最大回撤(%)	最大回撤天数
等权	21.22	12.83	26.12	8.27	0.81	1.55	48.10	18.13	65
历史 IC 加权	20.12	11.73	25.95	7.52	0.78	1.56	46.57	14.72	65
最大化 IC	21.92	13.52	25.97	6.47	0.84	2.09	48.34	6.56	65
最大化 IC_IR	11.64	3.25	25.56	6.40	0.46	0.51	63.96	19.38	817
Loss1 神经网络	17.48	9.09	25.73	6.46	0.68	1.41	50.95	10.92	817
DCM	24.89	16.50	25.31	7.16	0.98	2.31	46.92	6.76	65


资料来源：Wind，中信证券研究部

策略分析：在测试集上实现了更优的 Weighted IC

从训练集和测试集上的效果来看，DCM 有效提升了 Weighted IC。首先在训练集上，DCM 的 Weighted IC 显著优于等权模型和历史 IC 加权模型，较前者大概高出 3%，后者大概在 2%，这表明 DCM 在历史数据上的进行了有效的优化。


再从测试集上观察其泛化效果，可以看到大部分时间 DCM 的 Weighted IC 较对比模型也是更好的。

图 7：DCM 与等权模型和历史 IC 加权模型的 Weighted IC 的差（训练集）



资料来源：Wind，中信证券研究部

图 8：DCM 与等权模型和历史 IC 加权模型的 Weighted IC 的差（测试集）



资料来源：Wind，中信证券研究部

以下两图分别展示了基准模型处于不同的 Weighted IC 下时，DCM 带来的提升。可以很明显的看到，在基准模型 Weighted IC 为负的时候，即会产生回撤的时候，DCM 会带来显著的提升，当然在基本模型表现特别好的时候，DCM 会削弱表现。但总的来说，更加稳定的超额能够最大化的发挥复利效应，有效提升长期超额收益。

图 9：等权模型 Weighted IC VS. DCM Weighted IC-等权模型 Weighted IC

图 10：历史 IC 加权 Weighted IC VS. DCM Weighted IC-历史 IC 加权 Weighted IC



资料来源：Wind，中信证券研究部



资料来源：Wind，中信证券研究部

结论与投资建议

拟合目标收益的低信噪比极大地限制了深度学习在低频量化策略上的应用。为了解决这一问题，本报告将合成因子与收益的相关性作为优化目标，并采用深度网络实现映射关系的学习，构建了深度相关模型（Deep Correlation Model, DCM）。模型的核心包含以下四点：

1) 以 IC 为优化目标，一是更关注合成因子的相对大小关系，二是对同一期所有样本计算错误信号，信噪比会更高。

2) Weighted IC，可有效避免局部排序与整体相悖的“陷阱”，更好地适应多头选股的任务。

3) 神经网络设计：包含两层 32 个单元的全连接层，和两层批标准化层。

4) 损失函数：计算 Weighted IC 需要按合成因子的大小进行排序，与权重的顺序对应。对多期的损失计算指数衰减权重加权的作为最终的损失。

在 2012 年 1 月 1 日至 2021 年 10 月 26 日的区间上测试，DCM 策略实现 16.50% 的年化超额收益，信息率 2.31，超额最大回撤 6.76%。并且对比 DCM 和 Loss1 神经网络模型，结果显示更换目标函数后，年化超额收益提升了 7.41%，信息率提升了 0.9。

总的来说，设计更加合理的目标函数是一种通过提升错误信号的信噪比，从而提升策略性能的有效手段。基于相关性的目标函数较直接拟合收益年化超额收益提升了 7.41%，信息比率提升了 0.9。

风险因素

(1) 衍生品政策风险；(2) 模型风险；(3) 历史业绩不代表未来表现。

■ 相关研究

量化策略专题研究—财务视角下的负向组合构建研究	(2021-05-20)
量化策略专题研究—寻找业绩预期未被透支的黑马股	(2021-05-20)
量化策略专题研究—量化视角下的市场风格分析	(2021-04-10)
量化策略专题研究—AH 溢价因素的分析与策略应用	(2020-11-02)
量化策略专题研究—量化新闻情绪，把握投资先机	(2020-06-02)
量化策略专题研究—以史为鉴，可知兴替：模式识别视角的行业轮动策略	(2020-01-09)
量化策略专题研究—机器学习在量化投资中的应用探讨	(2020-02-05)
量化策略专题研究—行业趋势配置模型研究	(2020-03-25)
量化策略专题研究—公募持仓视角下的行业配置策略	(2020-03-25)
量化策略专题研究—顺势而为：行业趋势配置模型研究	(2020-04-09)
量化策略专题研究—寻找分析师前瞻观点中的 Alpha	(2020-05-14)

分析师声明

主要负责撰写本研究报告全部或部分内容的分析师在此声明：(i) 本研究报告所表述的任何观点均精准地反映了上述每位分析师个人对标的证券和发行人的看法；(ii) 该分析师所得报酬的任何组成部分无论是在过去、现在及将来均不会直接或间接地与研究报告所表述的具体建议或观点相联系。

评级说明

投资建议的评级标准		评级	说明
报告中投资建议所涉及的评级分为股票评级和行业评级（另有说明的除外）。评级标准为报告发布日后 6 到 12 个月内的相对市场表现，也即：以报告发布日后的 6 到 12 个月内的公司股价（或行业指数）相对同期相关证券市场代表性指数的涨跌幅作为基准。其中：A 股市场以沪深 300 指数为基准，新三板市场以三板成指（针对协议转让标的）或三板做市指数（针对做市转让标的）为基准；香港市场以摩根士丹利中国指数为基准；美国市场以纳斯达克综合指数或标普 500 指数为基准；韩国市场以科斯达克指数或韩国综合股价指数为基准。	股票评级	买入	相对同期相关证券市场代表性指数涨幅 20%以上
		增持	相对同期相关证券市场代表性指数涨幅介于 5%~20%之间
		持有	相对同期相关证券市场代表性指数涨幅介于-10%~5%之间
		卖出	相对同期相关证券市场代表性指数跌幅 10%以上
	行业评级	强于大市	相对同期相关证券市场代表性指数涨幅 10%以上
		中性	相对同期相关证券市场代表性指数涨幅介于-10%~10%之间
		弱于大市	相对同期相关证券市场代表性指数跌幅 10%以上

其他声明

本研究报告由中信证券股份有限公司或其附属机构制作。中信证券股份有限公司及其全球的附属机构、分支机构及联营机构（仅就本研究报告免责条款而言，不含 CLSA group of companies），统称为“中信证券”。

法律主体声明

本研究报告在中华人民共和国（香港、澳门、台湾除外）由中信证券股份有限公司（受中国证券监督管理委员会监管，经营证券业务许可证编号：Z20374000）分发。本研究报告由下列机构代表中信证券在相应地区分发：在中国香港由 CLSA Limited 分发；在中国台湾由 CL Securities Taiwan Co., Ltd. 分发；在澳大利亚由 CLSA Australia Pty Ltd.（金融服务牌照编号：350159）分发；在美国由 CLSA group of companies（CLSA Americas, LLC（下称“CLSA Americas”）除外）分发；在新加坡由 CLSA Singapore Pte Ltd.（公司注册编号：198703750W）分发；在欧盟与英国由 CLSA Europe BV 或 CLSA（UK）分发；在印度由 CLSA India Private Limited 分发（地址：孟买（400021）Nariman Point 的 Dalalal House 8 层；电话号码：+91-22-66505050；传真号码：+91-22-22840271；公司识别号：U67120MH1994PLC083118；印度证券交易委员会注册编号：作为证券经纪商的 INZ000001735，作为商人银行的 INM000010619，作为研究分析商的 INH000001113）；在印度尼西亚由 PT CLSA Sekuritas Indonesia 分发；在日本由 CLSA Securities Japan Co., Ltd. 分发；在韩国由 CLSA Securities Korea Ltd. 分发；在马来西亚由 CLSA Securities Malaysia Sdn Bhd 分发；在菲律宾由 CLSA Philippines Inc.（菲律宾证券交易所及证券投资者保护基金会）分发；在泰国由 CLSA Securities (Thailand) Limited 分发。

针对不同司法管辖区的声明

中国：根据中国证券监督管理委员会核发的经营证券业务许可，中信证券股份有限公司的经营经营范围包括证券投资咨询业务。

美国：本研究报告由中信证券制作。本研究报告在美国由 CLSA group of companies（CLSA Americas 除外）仅向符合美国《1934 年证券交易法》下 15a-6 规则定义且 CLSA Americas 提供服务的“主要美国机构投资者”分发。对身在美国的任何人士发送本研究报告将不被视为对本报告中所评论的证券进行交易的建议或对本报告中所载任何观点的背书。任何从中信证券与 CLSA group of companies 获得本研究报告的接收者如果希望在美国交易本报告中提及的任何证券应当联系 CLSA Americas。

新加坡：本研究报告在新加坡由 CLSA Singapore Pte Ltd.（资本市场经营许可持有人及受豁免的财务顾问），仅向新加坡《证券及期货法》s.4A（1）定义下的“机构投资者、认可投资者及专业投资者”分发。根据新加坡《财务顾问法》下《财务顾问（修正）规例（2005）》中关于机构投资者、认可投资者、专业投资者及海外投资者的第 33、34 及 35 条的规定，《财务顾问法》第 25、27 及 36 条不适用于 CLSA Singapore Pte Ltd.。如对本报告存有疑问，还请联系 CLSA Singapore Pte Ltd.（电话：+65 6416 7888）。MCI (P) 024/12/2020。

加拿大：本研究报告由中信证券制作。对身在加拿大的任何人士发送本研究报告将不被视为对本报告中所评论的证券进行交易的建议或对本报告中所载任何观点的背书。

欧盟与英国：本研究报告在欧盟与英国归属于营销文件，其不是按照旨在提升研究报告独立性的法律要件而撰写，亦不受任何禁止在投资研究报告发布前进行交易的限制。本研究报告在欧盟与英国由 CLSA（UK）或 CLSA Europe BV 发布。CLSA（UK）由（英国）金融行为管理局授权并接受其管理，CLSA Europe BV 由荷兰金融市场管理局授权并接受其管理，本研究报告针对由相应本地监管规定所界定的在投资方面具有专业经验的人士，且涉及到的任何投资活动仅针对此类人士。若您不具备投资的专业经验，请勿依赖本研究报告。对于由英国分析员编纂的研究资料，其由 CLSA（UK）与 CLSA Europe BV 制作并发布。就英国的金融行业准则与欧洲其他辖区的《金融工具市场指令 II》，本研究报告被制作并意图作为实质性研究资料。

澳大利亚：CLSA Australia Pty Ltd（“CAPL”）（商业编号：53 139 992 331/金融服务牌照编号：350159）受澳大利亚证券与投资委员会监管，且为澳大利亚证券交易所及 CHI-X 的市场参与主体。本研究报告在澳大利亚由 CAPL 仅向“批发客户”发布及分发。本研究报告未考虑收件人的具体投资目标、财务状况或特定需求。未经 CAPL 事先书面同意，本研究报告的收件人不得将其分发给任何第三方。本段所称的“批发客户”适用于《公司法（2001）》第 761G 条的规定。CAPL 研究覆盖范围包括研究部门管理层不时认为与投资者相关的 ASX All Ordinaries 指数成分股、离岸市场上市证券、未上市发行人及投资产品。CAPL 寻求覆盖各个行业中与其国内及国际投资者相关的公司。

一般性声明

本研究报告对于收件人而言属高度机密，只有收件人才能使用。本研究报告并非意图发送、发布给在当地法律或监管规则下不允许向其发送、发布该研究报告的人员。本研究报告仅为参考之用，在任何地区均不应被视为买卖任何证券、金融工具的要约或要约邀请。中信证券并不因收件人收到本报告而视其为中信证券的客户。本报告所包含的观点及建议并未考虑个别客户的特殊状况、目标或需要，不应被视为对特定客户关于特定证券或金融工具的建议或策略。对于本报告中提及的任何证券或金融工具，本报告的收件人须保持自身的独立判断。

本报告所载资料的来源被认为是可靠的，但中信证券不保证其准确性或完整性。中信证券并不对使用本报告所包含的材料产生的任何直接或间接损失或与此有关的其他损失承担任何责任。本报告提及的任何证券或金融工具均可能含有重大的风险，可能不易变卖以及不适合所有投资者。本报告所提及的证券或金融工具的价格、价值及收益可能会受汇率影响而波动。过往的业绩并不能代表未来的表现。

本报告所载的资料、观点及预测均反映了中信证券在最初发布该报告日期当日分析师的判断，可以在不发出通知的情况下做出更改，亦可因使用不同假设和标准、采用不同观点和分析方法而与中信证券其它业务部门、单位或附属机构在制作类似的其他材料时所给出的意见不同或者相反。中信证券并不承担提示本报告的收件人注意该等材料的责任。中信证券通过信息隔离墙控制中信证券内部一个或多个领域的信息向中信证券其他领域、单位、集团及其他附属机构的流动。负责撰写本报告的分析师的薪酬由研究部门管理层和中信证券高级管理层全权决定。分析师的薪酬不是基于中信证券投资银行收入而定，但是，分析师的薪酬可能与投行整体收入有关，其中包括投资银行、销售与交易业务。

若中信证券以外的金融机构发送本报告，则由该金融机构为此发送行为承担全部责任。该机构的客户应联系该机构以交易本报告中提及的证券或要求获悉更详细信息。本报告不构成中信证券向发送本报告金融机构之客户提供的投资建议，中信证券以及中信证券的各个高级职员、董事和员工亦不为（前述金融机构之客户）因使用本报告或报告载明的内容产生的直接或间接损失承担任何责任。

未经中信证券事先书面授权，任何人不得以任何目的复制、发送或销售本报告。

中信证券 2021 版权所有。保留一切权利。